

假如是你计算机科学与技术专业的学生，正要写 毕业论文和设计了，...

回答

研究报告：关于“基于 RAG 技术的校园规章制度咨询助手的设计与实现”毕业设计选题的综合评估

报告日期：2026 年 4 月 14 日

报告撰写人：资深 AI 技术研究员

评估对象：一份计算机科学与技术专业的毕业设计选题摘要

核心技术：检索增强生成 (Retrieval-Augmented Generation, RAG)

摘要重述与核心议题拆解

在进行深入评估之前，我们首先重述并拆解该毕业设计选题摘要的核心内容：

- **问题痛点：**高校规章制度存在“难查找、难理解、难适配”三大难题，传统问答系统则面临“信息孤岛”与响应滞后。这是一个非常精准且普遍存在于高等教育管理中的现实问题。
- **解决方案：**提出并实现一个基于检索增强生成（RAG）技术的校园规章制度咨询助手。
- **技术架构：**
- **基座：**大语言模型 (LLM)。
- **核心技术：**RAG、向量数据库。

- **系统模块：** 知识库构建、混合检索、智能生成。

- **实现流程：**

- 1.**数据预处理：** 对非结构化文档进行解析、分词、语义切分，并通过嵌入模型（Embedding Model）向量化后存入向量数据库。

- 2.**问答流程：** 采用混合检索策略召回知识片段，作为上下文（Context）输入 LLM，约束其生成基于本地知识的准确回答。

- 3.**预期效果：** 缓解 LLM 在垂直领域的幻觉问题和语义理解偏差，在意图识别和答案准确率上显著优于基座模型，实现知识的动态更新与精准问答。

- 4.**价值贡献：** 为高校管理智能化与数字化转型提供创新方式与实践参考。

第一章：选题的前沿性、可行性与学术价值综合评估

本章旨在从宏观层面评估该选题作为一篇 2026 年的计算机科学毕业论文的整体质量，包括其技术前沿性、项目可行性以及学术与实践价值。

1.1 技术前沿性分析：紧扣 AI 发展脉搏

截至 2026 年初，大语言模型（LLM）的应用已经从通用聊天机器人阶段，深入到各行各业的垂直领域落地。单纯依赖通用 LLM（如 GPT 系列、Llama 系列）进行微调（Fine-tuning）的模式，因其高昂的训练成本、更新困难以及在专业领域中仍无法根除的“幻觉”问题，其局限性日益凸显。

正是在此背景下，检索增强生成（RAG）技术在过去两到三年（2023-2025 年）中迅速崛起，成为将 LLM 能力与私有或专业知识库相结合的主流范式 [[1]][[2]]。RAG 通过“先检索，后生成”的机制，为 LLM 提供了实时的、可信的、领域特定的知识源，从而极大地提升了回答的准确性和可靠性 [[3]][[4]]。

该选题精准地捕捉到了这一技术趋势。它没有停留在“如何使用 LLM”的浅层问题上，而

是深入到“如何更好地将 LLM 应用于特定领域”的核心挑战中。选择 RAG 作为核心技术，本身就体现了对当前 AI 应用开发领域最新进展的深刻理解。特别是在 2026 年，业界对 RAG 的探索已经从基础实现，发展到对检索策略、分块方法、多模态融合、动态知识更新等更深层次的优化 [[5]]。因此，该选题在技术栈的选择上具备高度的前沿性。

1.2 项目可行性与工作量评估

对于一篇本科毕业设计而言，选题必须在具有挑战性的同时，确保在有限的时间和资源内可以完成。我们从技术实现和工作量两个维度进行评估。

1.2.1 技术实现的可行性

- **成熟的开源生态：**到了 2026 年，围绕 RAG 的开发工具链已经相当成熟。诸如 LangChain、LlamaIndex 等框架极大地降低了构建 RAG 应用的门槛，它们封装了数据加载、文本切分、向量化、检索、与 LLM 交互等复杂流程 [[6]]。

- **丰富的模型选择：**

- **LLM：**市场上存在大量可选的 LLM，既有性能强大的闭源 API（如 OpenAI 的 GPT-4.1 系列、Mistral Large） [[7]][[8]]也有效果优异、可供本地化部署的开源模型（如 Llama 3.1 8B, Mistral 7B, GLM-4） [[9]][[10]][[11]]。这为学生提供了根据实际设备和预算进行选择的灵活性。

- **Embedding Model：**同样，嵌入模型的选择也极为丰富，从经典的 all-MiniLM 系列到效果更佳的 BGE (BAAI General Embedding)系列（如 bge-large-zh-v1.5）和 GTE 系列，这些模型在 Hugging Face 等平台上唾手可得，并且有大量关于其性能评测的公开数据 [[12]][[13]][[14]]。

- **向量数据库：**开源向量数据库如 Milvus, Qdrant, Chroma, Faiss 等技术成熟，社区活跃，文档齐全，部署和使用难度对于计算机专业的学生来说是可控的 [[15]][[16]][[17]]。

- **清晰的实现路径：**摘要中描述的“知识库构建 -> 混合检索 -> 智能生成”的三大模块，构成了一个标准且清晰的 RAG 系统实现蓝图。这表明选题人对项目有着明确的规划，降低了项目失控的风险。

1.2.2 工作量评估

根据相关软件开发工作量评估标准，该项目的难度可评为“中等偏上”，工作量饱满，非常适合作为一篇优秀的毕业设计 [[18]][[19]][[20]]。

● 核心工作量分布：

1.数据层（工作量：大）： 这是最耗时且最容易被低估的部分。高校规章制度通常以 PDF、Word、HTML 等多种格式存在，格式混乱，包含大量表格、页眉页脚、水印等噪声。仅数据清洗、解析和结构化提取就是一个不小的工程挑战。

2.模型与算法层（工作量：中）： 包括选择和配置 LLM、Embedding 模型；设计并实现文本切分策略（Chunking Strategy）；实现混合检索算法（如 BM25 + 向量检索）；设计高效的 Prompt Engineering 模板。

3.系统实现层（工作量：中）： 使用 Python（如 Flask/FastAPI）搭建后端服务，集成各个模块，并可能需要开发一个简单的前端界面（Web 或命令行）用于交互和展示。

4.评测层（工作量：大）： 设计并构建评测体系是体现论文学术深度的关键。这包括创建高质量的评测问答对（QA pairs）、选择合适的评测指标、编写自动化评测脚本、进行多次实验并分析结果。这部分的工作量不亚于核心功能的开发 [[21]][[22]]。

综上，该选题的工作量足以支撑一篇毕业论文的体量，且核心模块界定清晰，允许在时间紧张时进行范围裁剪（例如，初期只支持部分学院的规章，或简化前端界面），保证了项目的可完成性。

1.3 学术价值与实践意义

● 学术价值：

1.垂直领域应用的实证研究： 该项目是对 RAG 技术在“高等教育管理”这一高度垂直且知识密集型领域的一次深度实证研究。论文的成果可以为 RAG 在其他类似领域（如法律、金融、医疗）的应用提供宝贵的经验和数据。

2.模型能力边界的探索：通过对比 RAG 系统与基座 LLM 在特定任务上的表现，可以清晰地展示 RAG 在缓解幻觉、提升领域知识准确性方面的具体效果，为 LLM 的能力边界和优化路径提供了有力的学术证据 [[23]]。

3.评测体系的构建：为垂直领域知识问答系统设计一套科学、全面的评测指标和方法论，本身就具有学术价值。摘要中提到的“意图识别准确率”和“答案准确率”是基础，论文中可以进一步扩展到忠实度（Faithfulness）、答案相关性（Answer Relevance）、上下文相关性（Context Relevance）等更细致的 RAG 专项评测维度 [[24]][[25]][[26]]。

4.实践意义：

1.解决高校实际痛点：该系统直面师生在日常工作中遇到的信息获取难题，能够极大地提升行政效率和师生满意度。例如，新生可以快速了解报到流程、奖学金申请条件；教职工可以便捷查询财务报销、科研项目申报等规定。

2.推动高校智慧管理：这是一个典型的“AI+教育管理”应用，是高校数字化转型和智慧校园建设中的一个具体、可落地的切入点 [[27]][[28]]。其成功实践可以作为案例，启发更多校园管理场景的智能化升级。

3.知识管理的现代化：该系统将静态、分散的规章制度文档，转化为了一个动态、可交互的智能知识库，实现了知识的高效利用和传承，这本身就是一种管理模式创新 [[29]][[30]]。

第二章：核心技术模块的深度剖析与优化建议

本章将深入摘要中提到的三大核心模块，结合 2026 年的技术现状和搜索结果，进行详细的技术分析，并提出可供选题人参考的深化和优化方向。

2.1 知识库构建模块：从“能用”到“好用”的基石

摘要中提到了“解析、分词与语义切分”，这涵盖了知识库构建的核心流程。但要构建一个高质量的知识库，每一步都充满挑战和优化空间。

2.1.1 文档解析与预处理

● **挑战：** 高校规章制度通常是包含复杂格式的 PDF 文档，其中混杂着表格、列表、图表、页眉页脚等。直接提取纯文本会丢失大量结构化信息，甚至破坏语义。例如，一个关于奖学金评定标准的表格，如果被粗暴地转为纯文本，其行列关系将不复存在，LLM 难以正确理解。

● **深度实现建议：**

● **采用先进的文档解析工具：** 不应满足于简单的 PyPDF2 等库。应研究并使用如 unstructured.io、LlamaParse 或结合 OCR 技术的方案（如 PaddleOCR），这些工具能更好地解析 PDF 中的表格、列表等结构，并将其转换为 Markdown 或 JSON 等半结构化格式。

● **处理表格数据：** 对于解析出的表格，不应将其简单地线性化为文本。可以尝试将其转换为 CSV 格式或直接在 Prompt 中以 Markdown 表格形式提供给 LLM，以最大限度地保留其结构信息。有研究表明，这能显著提升 LLM 对表格内容的理解能力 [[31]]。

● **元数据（Metadata）提取与利用：** 在解析文档时，应尽可能提取元数据，如文件名、发布日期、发布部门、制度的生效/失效日期、版本号等。这些元数据在后续的检索过滤和版本控制中至关重要。

2.1.2 文本切分（Chunking）策略

摘要中提到的“语义切分”是关键。这是决定 RAG 系统召回质量的“咽喉”环节。

● **传统方法的局限：** 简单的固定长度切分（Fixed-size Chunking）或递归字符切分（Recursive Character Text Splitting）虽然实现简单，但极易在语义单元的中间断开，导致上下文信息不完整 [[32]][[33]]。

● **“语义切分”的深化实现：**

● **基于规则的结构化切分：** 利用文档的章节（如“第一章”、“1.1 节”）、段落、标题等自然结构进行切分。这要求预处理阶段能准确识别这些结构。

- **基于 NLP 的句子切分：**使用 spaCy 或 NLTK 等库，将文档先切分为句子，再将语义相近的连续句子组合成一个 Chunk。

- **基于嵌入模型的语义切分 (Semantic Chunking)：**这是一种更先进的方法。它计算连续句子（或小段落）之间嵌入向量的余弦相似度。当相似度出现一个“断崖式”下降时，就认为这里是一个语义边界，适合进行切分 [[34]][[35]]。这种方法能最大程度地保证每个 Chunk 内部的语义连贯性。

- **Agentic Chunking：**2025-2026 年兴起的一种更智能的思路，利用一个强大的 LLM（如 GPT-4）作为“切分智能体”，让它阅读一小段文本后，自己判断在哪里切分最合理。虽然成本较高，但在处理复杂、无明显结构化特征的文本时效果优异。

- **最佳实践建议：**毕业设计中可以实现并对比多种切分策略，例如，实现一个基础的递归字符切分作为 Baseline，然后重点实现并优化一种语义切分策略，通过实验数据证明其优越性。

2.1.3 嵌入模型与向量数据库的选择

- **Embedding Model：**

- **选型考量：**应重点选择在中文任务上表现优异，并且与计划使用的 LLM 在语义空间上较为匹配的模型。BGE 系列（如 bge-large-zh-v1.5）和多语言的 E5 系列都是 2026 年非常可靠的选择 [[36]][[37]]。选题人应参考最新的 MTEB (Massive Text Embedding Benchmark) 等权威榜单的中文评测结果。

- **微调可能性：**若想进一步提升深度，可以考虑在小规模的校园领域相关问答对上对 Embedding 模型进行微调，使其更懂校园“黑话”（如“二学位”、“保研”、“青教赛”等）。

- **向量数据库：**

- **技术对比：**

- **Milvus:** 功能强大，高度可扩展，支持多种索引类型和相似度计算方法，适合大规模、高

并发的企业级应用。对于一个完整的校园系统来说，是未来的理想选择 [[38]][[39]][[40]]。

- **Qdrant:** 用 Rust 编写，性能优秀，尤其在元数据过滤（filtered search）方面表现突出，资源消耗相对较低。如果系统需要频繁根据“发布年份”、“所属部门”等元数据进行筛选后检索，Qdrant 是一个极具吸引力的选项 [[41]][[42]]。

- **Chroma/FAISS:** 更轻量级，Chroma 尤其易于上手和集成，适合项目初期快速原型验证。FAISS 是 Facebook AI 推出的库，性能极高，但更多是一个底层库，需要自行封装服务 [[43]][[44]]。

- **选型建议：** 对于毕业设计，建议从 Chroma 入手快速搭建原型。在论文中，可以专门设立一节，对 Milvus 和 Qdrant 进行调研和性能对比分析，阐述在未来生产环境下为何会选择其中之一，这能显著提升论文的技术深度 [[45]]。

2.2 混合检索模块：确保“找得准、找得全”

摘要中的“混合检索”是提升召回率和精确率的关键。

- **为何需要混合检索：**

- **向量检索（语义检索）：** 擅长理解“同义不同词”的模糊查询。例如，用户问“没钱交学费怎么办”，它可以召回关于“助学贷款”、“困难补助”、“绿色通道”的相关条例。

- **关键词检索（如 BM25/TF-IDF）：** 在处理包含特定术语、编号、人名等专有名称的查询时表现更佳。例如，用户问“《XXX 大学本科生学籍管理规定》的第十五条是什么”，关键词检索能精准定位。

- **实现策略：**

1. **并行检索与融合：** 分别执行向量检索和关键词检索，然后对两路结果进行融合。融合策略是研究的重点，简单的方法是加权组合分数，但更高级的方法是使用重排序模型（Re-ranking Model）。

2.重排序 (Re-ranking)： 将两路召回的前 K 个结果（例如，总共 20 个文档块）合并，然后使用一个更强大的 Cross-Encoder 模型对“查询”和每个“文档块”的对 (pair) 进行打分，根据这个更精确的相关性分数重新排序，最后选择 Top-N（例如，Top 3-5）个文档块作为最终上下文。这在 2026 年已被证明是提升 RAG 性能的 SOTA (State-of-the-Art) 方法之一。

3.深化建议： 论文中不仅要实现混合检索，更要花篇幅研究和实验不同的融合策略和重排序模型，并用评测数据（如 MRR, NDCG@k）来量化不同策略带来的提升 [[46]][[47]]。

2.3 智能生成模块：确保“说得对、说得好”

这是 RAG 的最后一环，也是直接面向用户的一环。

● **Prompt Engineering 的艺术：** 约束 LLM 基于本地知识生成回答的核心在于精心设计的 Prompt。一个好的 Prompt 模板通常包含：

● **角色设定：** "你是一个精通 XX 大学所有规章制度的智能助手，你的回答必须严谨、准确、并基于我提供的上下文。"

● **上下文注入：** Context: {retrieved_chunks}

● **任务指令：** "请根据以上上下文，回答用户的问题。如果上下文中没有足够信息，请明确告知用户'根据现有资料无法回答该问题'，严禁自行编造。"

● **用户问题：** Question: {user_query}

● **格式要求：** "请用清晰、分点的形式回答。如果可能，请在回答的每一部分后面注明信息来源的文档名称和章节。"

● **处理多轮对话上下文：**

● **挑战：** 用户的问题常常是连续的，例如：“申请奖学金需要什么条件？” -> “那对英语四级有要求吗？”。系统需要理解第二问中的“那”指的是“奖学金申请”。

● 实现方法：

1. **对话历史管理**：将最近的几轮对话历史一并加入到 Prompt 中。

2. **查询重写 (Query Rewriting)**：在进行检索之前，先用一个 LLM 将会话历史和当前问题作为输入，生成一个独立的、包含完整上下文的新查询。例如，将 {"history": "Q:申请奖学金需要什么条件? A:... ", "current_q": "那对英语四级有要求吗? "} 重写为 "申请奖学金对英语四级有要求吗? "。然后再用这个重写后的查询去进行检索。这是 2026 年处理 RAG 多轮对话的主流且高效的方法 [[48]][[49]]。

● **生成溯源 (Citation)**：这是提升系统可信度的关键功能。系统不仅要给出答案，还要能告诉用户答案是基于哪份文件的哪个部分。实现上，可以在检索到的文档块中包含其元数据（文件名、页码、章节号），并在 LLM 生成答案后，通过后处理步骤，将答案内容与来源块进行匹配，从而附上引用。

第三章：选题的创新性与差异化分析

摘要中提到该系统是“创新方式”，我们需要深入分析其创新点在何处，以及相比现有研究和系统，它可以做出哪些差异化贡献 [[50]][[51]][[52]]。

3.1 核心创新点分析

1. **动态知识更新机制**：这是摘要中一个非常亮眼的提法，也是一个重要的创新点。传统知识库是一次性构建，更新困难。一个真正有用的规章制度系统必须能跟上制度的“增、删、改”。

* **如何实现：**

* **增量更新流程**：设计一个自动化的 ETL (Extract, Transform, Load) 管道。该管道可以定期（如每天一次）扫描学校官网的“通知公告”、“制度文件”等板块。

* **版本控制与一致性：**

- * 通过比对文件名、发布日期或文件内容的哈希值，识别出新增或更新的文档。
- * 对于更新的文档，不是简单覆盖，而是采用版本管理策略。在向量数据库中，可以为同一份制度的不同版本向量赋予不同的版本号或时间戳元数据 [[53]][[54]][[55]]。
- * 在检索时，默认检索最新版本的文档，但也要支持用户查询历史版本。
- * **冲突检测：**这是一个更具挑战性的创新点。利用 LLM 的语义理解能力，可以初步检测新发布的制度是否与现有制度在某些条款上存在潜在冲突（例如，同一事项在两个文件中规定不一）。系统可以将这些潜在冲突点标记出来，供人工审核 [[56]]。
- * **差异化：**大多数基础的 RAG 教程和项目都侧重于静态知识库的搭建，而一个鲁棒的动态更新与版本管理机制，将是本论文一个巨大的工程和学术亮点 [[57]][[58]][[59]]。

2. 混合检索与重排序的深度优化：

- * 如 2.2 节所述，单纯实现混合检索已不新奇，但深入研究不同检索策略的融合权重、设计或微调一个适用于规章制度文本的重排序模型（Cross-Encoder），并通过详尽的实验证明其有效性，这构成了算法层面的创新。

3. 面向“适配”的个性化问答：

- * 摘要中的“难适配”直指规章制度的普适性与个体情况的差异性。一个创新的方向是实现“上下文感知”的个性化问答。
- * **如何实现：**系统在获得用户授权后，可以接入其基本画像（例如：通过校园统一身份认证获取用户的年级、学院、专业、政治面貌等信息）。当用户提问时，系统将这些个人信息作为额外的上下文，与问题一起进行查询重写或直接注入最终的生成 Prompt 中。
- * **示例：**用户问“我能申请这个奖学金吗？”。系统结合该用户是“大二、软件工程专业、党员”的画像，去检索和判断该奖学金的申请条件是否匹配，从而给出“根据你的情况，你满足 A、B 条件，但不满足 C 条件（要求大三以上）”这样高度个性化和适配的回答。这远比给出一份通用的申请条件要有价值得多。

4. 结构化知识与非结构化知识的融合（GraphRAG）：

- * 这是一个极具前瞻性的创新方向。除了向量数据库中的非结构化文本块，还可以构建一个知识图谱（Knowledge Graph），来存储规章制度之间的结构化关系（例如，《A 规定》是《B 规定》的实施细则）、实体（如“教务处”、“研究生院”）及其职责等。
- * 在 RAG 流程中，可以先通过知识图谱进行初步的推理和相关实体、规定的定位，然后将这些信息作为引导，再去向量数据库中进行更精准的文本块检索。这种 GraphRAG 的方法能更好地处理需要多步推理的复杂问题 [[60]]。

3.2 与现有研究的差异

- **相比通用 RAG 研究：**通用 RAG 研究更多关注算法本身（如更高效的检索、更长的上下文窗口），而本选题的价值在于将这些通用技术应用到“高校规章”这一具体、复杂且有价值的场景中，进行深度的工程实践和场景优化，产出的是领域内的“最佳实践”（Best Practice）。
- **相比其他校园问答系统：**许多现有的校园问答机器人是基于 FAQ 的检索式问答或简单的意图识别+模板回复，无法处理长文本和复杂推理 [[61]]。本选题利用 LLM 的生成和理解能力，实现了从“信息匹配”到“知识理解与生成”的跨越。相比同样使用 RAG 的校园问答系统案例 [[62]][[63]]本选题可以聚焦于“动态更新”、“个性化适配”、“制度冲突检测”等更深层次的功能，形成差异化优势。

第四章：评测体系的构建与科学性

一份优秀的毕业论文，其结论的可靠性高度依赖于评测体系的科学性。摘要中“评测实验表明...显著优于基座模型”的论断需要强有力的数据支撑。

4.1 构建高质量的评测数据集

- **数据来源：**
- **真实问题收集：**从学校的贴吧、论坛、咨询邮箱、教务处 FAQ 等渠道收集师生们实际

提出的问题。

- **人工构建：**针对规章制度的重点、难点、易混淆点，由选题人模拟不同身份（新生、毕业生、青年教师等）设计问题。

- **数据集构成：**

- **问题类型要丰富：**包括事实查询型（“报销需要哪些材料？”）、是非判断型（“大一学生可以转专业吗？”）、比较型（“A 奖学金和 B 奖学金有什么区别？”）、推理型（“我上学期挂了一科，会影响我评优吗？”）等。

- **“黄金答案”与来源标注：**每个问题都需要有一个人工核实和撰写的标准答案，并清晰标注答案所依据的规章制度原文片段。

- **包含“无法回答”的案例：**数据集中应包含一些现有规章制度无法覆盖或信息不足的问题，用于评测系统拒绝回答（而非幻觉）的能力 [[64]]。

4.2 设计多维度、分层次的评测指标

除了摘要中提到的“意图识别准确率”和“答案准确率”，一个全面的评测体系应包含以下三个层次：

1. 检索模块评测（Component-level: Retrieval）：

- * **Precision@k, Recall@k:** 召回的前 k 个文档块中有多少是与标准答案相关的。

- * **Mean Reciprocal Rank (MRR):** 第一个相关文档块出现的排名的倒数的平均值，衡量找到第一个正确答案的速度。

- * **Normalized Discounted Cumulative Gain (NDCG@k):** 综合考虑了召回文档的相关性程度和其在结果中的位置，是衡量排序质量的黄金指标 [[65]][[66]]。

2. 生成模块评测（Component-level: Generation）：

- * **RAGAS 框架**: 这是 2026 年评测 RAG 生成质量的主流框架, 它利用 LLM 作为评委, 从多个维度自动化打分, 非常适合本选题 [[67]][[68]][[69]]。
- * **Faithfulness (忠实度)**: 生成的答案是否完全基于提供的上下文, 没有添加外部信息或产生幻觉。
- * **Answer Relevancy (答案相关性)**: 生成的答案是否直接、精准地回答了用户的问题。
- * **Context Precision & Context Recall (上下文精确率/召回率)**: 提供的上下文中, 信噪比如何? 是否包含了所有回答问题所需的必要信息?

3. 端到端评测 (End-to-End Evaluation) :

- * **答案准确率 (Accuracy)** : 将系统生成的最终答案与“黄金答案”进行比对。对于生成式任务, 可以采用基于 LLM 的自动评判 (判断二者语义是否一致) 或人工评判。
- * **用户满意度调研**: 设计调查问卷, 邀请一小部分真实用户试用系统, 并从答案的准确性、易懂性、响应速度、交互体验等多个方面收集主观反馈。
- * **A/B 测试**: 将本系统与基座 LLM (无 RAG)、传统关键词搜索系统进行对比实验, 让用户盲测并评价哪个系统的回答更好, 用数据证明本系统的优越性 [[70]][[71]]。

第五章：部署与未来展望的思考

虽然毕业设计可能止步于原型系统, 但在论文中展现对实际部署和未来发展的思考, 能极大提升其完整性和深度。

5.1 安全性与隐私保护

- **数据安全**: 规章制度本身可能包含未公开的草案, 用户的查询可能涉及个人隐私。因此, 系统在设计之初就应考虑安全问题。最佳实践是采用**本地化部署**方案, 即将开源 LLM、Embedding 模型和向量数据库全部部署在校园内网的服务器上, 确保所有数据不出校, 避免了调用外部 API (如 OpenAI) 可能导致的数据泄露风险 [[72]][[73]][[74]]。

● **访问控制：** 对于一些敏感的、有阅读权限限制的规章（如人事、财务的内部文件），需要设计基于角色的访问控制（RBAC）机制。系统需与学校的统一身份认证系统打通，根据用户的身份（学生、教师、特定部门管理员）来过滤其可检索的知识范围，确保合规性 [[75]][[76]][[77]]。

5.2 未来发展方向

● **多模态支持：** 未来的规章制度可能会包含流程图、示意图等。系统可以扩展为多模态 RAG，能够理解图片内容，实现图文联合问答 [[78]]。

● **主动推送与预警：** 结合动态更新机制，当有与用户画像（如学院、年级）高度相关的新规章发布或重要变更时，系统可以向用户主动推送提醒。

● **成为决策辅助工具：** 对于管理者，系统可以进化为规章制度的“模拟器”。例如，在制定新规时，管理者可以输入草案，系统能够快速分析其与现有制度的关联和潜在冲突，辅助决策。

第六章：结论与最终建议

综合以上全方位、多角度的深度分析，我们对该毕业设计选题做出如下最终评价与建议：

1. 选题综合评价：优秀

该选题是一个非常优秀的计算机科学毕业设计题目。它具备以下特质：

- * **高前沿性：** 紧扣 RAG 这一当前 AI 应用领域的热点和主流技术。
- * **高可行性：** 技术路径清晰，开源生态成熟，工作量饱满且可控。
- * **高价值性：** 兼具显著的学术研究价值和解决现实痛点的实践意义。
- * **高延展性：** 选题的深度和广度都留有充足的探索空间，易于做出亮点和创新。

2. 对选题人的建议：

* **明确核心创新点：** 选题的成功关键在于“做出差异化”。建议从前述的“动态知识更新与版本管理”、“个性化适配问答”、“制度冲突检测”或“深度优化的混合检索与重排序”中，选择 1-2 个作为论文的核心攻关方向和创新亮点。

* **重视数据工程：** 切勿低估前期数据清洗和处理的难度和重要性。一个高质量、干净、结构化的知识库是整个系统的基石。

* **以评测为导向：** 在项目初期就应着手设计评测方案和构建评测数据集。整个开发过程应以提升评测指标为目标，这会让论文的逻辑更清晰，结论更有力。

* **注重论文撰写：** 在论文中，不仅要描述“做了什么”（What），更要深入阐述“为什么这么做”（Why）以及“做得怎么样”（How well）。例如，不仅要说用了混合检索，更要解释为什么需要混合检索，对比了哪些方案，最终方案效果如何，并用数据说话。

总之，该选题为学生提供了一个绝佳的机会，去完整地经历一个前沿 AI 应用从问题定义、技术选型、系统设计、开发实现到科学评测的全过程。如果能够按照上述分析中的深度和广度去完成，这篇毕业论文无疑将具备极高的质量，并能充分展现该学生扎实的专业功底、前沿的技术视野和优秀的工程实践能力。我们对此选题予以高度肯定和强烈推荐。

文献来源

[5]. [Language Models are Few-Shot Learners](#)

[184]. [2026 与时光共前行](#)

[310,314]. [Marcel: A Lightweight and Open-Source Conversational Agent for University Student Support](#)

以下来源未被直接引用

[PyTorch: An Imperative Style, High-Performance Deep Learning Library](#)

[Attention is All you Need](#)

其他来源

- [1,494]. Ovis: Structural Embedding Alignment for Multimodal Large Language Model
- [2,21,423,425]. Retrieval-Augmented Social Media Intelligence: Detecting and Reporting of High-Risk Communication Patterns using Large Language Models
- [3,424,426]. Integrations - Securiti
- [4,15,427,430,452]. Artificial Intelligence Master of History
- [6,10,22,429]. Realisierung eines Document-Retrieval-Systems mit Large Language Models
- [7,23,422]. Answer validation using Large Language Model Systems
- [8,24]. embedding
- [9,12,428]. SoroIA: Diseño e Implementación de un Sistema Conversacional basado en Modelos Grandes de Lenguaje para el Museo Sorolla
- [11]. Hands-On Large Language Models: Language Understanding and Generation
- [13]. Enhancing Review-based Recommender Systems with Attention-driven Models Leveraging Large Language Model's Embeddings
- [14,453]. Automation of the Request for Quotation Process using Large Language Models
- [16]. SecuredGPT: Pilotbetrieb eines On-Premises Large Language Model im Wissensmanagement
- [17]. An Interactive Question-Answering System using Large Language Model and Retrieval-Augmented Generation in An Intelligent Tutoring System on the Programming Domain
- [18]. Study of usage of Large Language Model in industrial context
- [19]. Large Language Model Empowered Embedding Generator for Sequential Recommendation
- [20]. 大规模语言模型在复杂系统仿真与预测中的应用
- [25,28,34,37,41,44,462,481]. Personalized Fake News Aware Recommendation System

- [26,29,30,38,42,45,46,482]. Scalable Computing: Practice and Experience
- [27,36,39,487]. A TEMPORAL EXPERT FINDING METHODOLOGY BASED ON UNITED AUTHOR-DOCUMENT-TOPIC GRAPHS
- [31,40]. Baseline vs. Benchmark
- [32]. Benchmark Testing
- [33]. Baseline Data: Build a Reliable Foundation for Measuring Change
- [35,43,486]. 4th International Conference on Advanced Technologies, Computer Engineering and Science (ICATCES 2025)
- [47]. A Cross-Benchmark Comparison of 87 Learning to Rank Methods
- [48,50,52,56,473]. A Dynamic Knowledge Base Updating Mechanism-Based Retrieval-Augmented Generation Framework for Intelligent Question-and-Answer Systems
- [49,51,474]. Dynamic Knowledge Bases
- [53,62,469]. Open-AutoGLM 智能体的核心理念与架构演进
- [54]. Small-Sample Thermal Fault Diagnosis Using Knowledge Graph and Generative Adversarial Networks
- [55]. RUL: a Declarative Language for Updating RDF Data
- [57]. KNOWLEDGE-BASED SYSTEMS: Overview and Selected Examples
- [58,66,67,68]. A partial solution to knowledge base consistency maintenance in an evolving advisory system
- [59,60,63,64]. Dynamic Knowledge Representation and its Applications
- [61]. An abductive framework for computing knowledge base updates
- [65,71]. Semantic Completeness and Mathematical Properties of DIKWP Mathematical System
- [69]. Ensuring Consistency of Dynamic Knowledge Graphs through Logical Graph Transformations
- [70,72]. Reliable Reference for a DL Knowledge Base under Data Update

- [73,86,417]. 大模型浪潮商业机遇、产业变革与未来趋势
- [74,418]. Identyfikacja przykładów dobrych praktyk nowatorskich rozwiązań w kształceniu zawodowym
- [75,419]. 数字原生典型案例集 2024-2025
- [76,88]. 基于 RAG 的问答系统实现与优化
- [77,79,81,151,152,156,158,159,161,165,386,447,478]. Design of a RAG-based Q&A System for University Academic Administration Assistants
- [78,408,416]. Intelligent Q&A application of rules and regulations based on large models and RAG technology
- [80,82,479]. Marcel: A Lightweight and Open-Source Conversational Agent for University Student Support
- [83,90]. 2025 年课程知识库建设完整指南：从技术架构到教学实践
- [84,87,89]. 中国企业 GEO 转型与应用趋势白皮书
- [85,297,299,307,492]. 字节跳动 RAG 实践手册
- [91,387,392]. AI 时代高校门户网站内容生态变革与智能知识库建设
- [92,95,98,113,440,483]. RAGAs 评估
- [93,96,99,441]. 从 0 到 1 开发企业级 AI 问答系统（含向量库选型+性能优化）
- [94,97,100,101,116]. RAG 技术全解析：打造下一代智能问答系统-阿里云开发者社区
- [102,402]. REFRAG: Rethinking RAG based Decoding
- [103,104,106]. RAG（Retrieval-Augmented Generation）技术原理与实战应用
- [105,107]. RAG 技术简介
- [108,112,463,480]. Retrieval-Augmented Generation for Large Language Models: A Survey
- [109]. A Systematic Review of Key Retrieval-Augmented Generation (RAG) Systems: Progress, Gaps, and Future Directions
- [110,397,401]. Document Similarity with Retrieval-Augmented Generation: A Generative AI

Approach

- [111]. RAG-based Question-Answering System for Algerian Tax law Context
- [114,442,484]. 评估 RAG 应用和 RAGA 的方法
- [115,117,485]. 检索增强生成 (RAG) 导论
- [118,119]. RAG 系统问答准确度的关键
- [120]. Measurement of retrieved chunk quality from real-world knowledge in retrieval-augmented generation: A Phase 1 foundational study
- [121,124,475]. RAG 核心技术及实现方法解析
- [122,348,353,356,358,438]. RAG (Retrieval-Augmented Generation) 的核心概念、组件与工作原理
- [123,150,160,162]. PoliChat: Retrieval Augmented Generation on University Documents and Regulations
- [125,131]. RAG 面试基本问题
- [126]. Evaluation of a Retrieval-Augmented Generation-Powered Chatbot for Pre-CT Informed Consent: a Prospective Comparative Study
- [127]. 為什麼要持續更新 RAG 知識庫？
- [128,140,443]. 本地化部署学科答疑机器人：RAG 技术在教育领域的应用与价值
- [129]. SecRAG: A Graph-Enhanced RAG Framework with Dynamic Prompt for Cybersecurity Applications
- [130]. RAGOps: Operating and Managing Retrieval-Augmented Generation Pipelines
- [132,133,445,470]. 构建高准确率 RAG 系统，从语料质量与拆分策略做起
- [134]. 城市全域数字化转型 城市数字底座 建设指引
- [135,141]. AI 赋能公司规章制度：效率与合规的平衡之道
- [136]. 大模型智能体暑期研学营——记忆管理与检索增强
- [137,446,471]. Spring AI 框架中 RAG 技术的实现与应用

- [138]. 大学文化素质教育第二课堂与校园文化共建研究
- [139]. A Regulatory Document Question-Answering Large Language Model for Campus Regulations
- [142,145,147,154,157,309,466,477]. 检索增强生成技术支持下的校园问答系统研究
- [143,393,394]. GPT-only vs. GPT with RAG: A Study on Accuracy in Handling University-Specific Queries
- [144,148,155]. ISIITA 2025
- [146,167,420,439]. SVILUPPO DI UN'APP ANDROID PER LO STUDIO BASATA SU SISTEMA RAG (RETRIEVAL-AUGMENTED-GENERATION)
- [149]. Evaluación de coherencia en respuestas generadas por un Chatbot para consulta de legislación y reglamentos universitarios
- [153,169,385]. An Empirical Study of Multi-Agent RAG for Real-World University Admissions Counseling
- [163,164,467]. RuleRAG: Rule-Guided Retrieval-Augmented Generation with Language Models for Question Answering
- [166,170]. Retrieval-Augmented Generation for Domain-Specific Question Answering: A Case Study on Pittsburgh and CMU
- [168]. RAG 在课堂问答中的应用：基于向量和图的检索范式比较
- [171]. RAG 研究现状
- [172,173,175,182,183,346,347,365,368,370,371]. Engineering RAG Systems for Real-World Applications: Design, Development, and Evaluation
- [174,177,352,355,357,367,369]. 2026 年构建生产级 RAG 系统实战指南：从文档到部署
- [176]. 清华计算机系斩获 SIGIR 2024 两大奖项
- [178,179,434]. 2026 计算机毕业设计选题指南：50 个高通过率题目推荐，避开天坑轻松毕业
- [180,435]. 2026 届计算机毕业设计 50 个高通过率选题推荐：大数据+SpringBoot+小程序全

覆盖, 附创新点详解

[181,360,363,436]. 软件开发工作量评估及软件开发工作量评估标准

[185]. 锐捷网络亮相 CERNET 华东南地区学术年会, 共绘 “AI+智慧校园” 高质量发展新图景

[186]. 工程总承包企业 PC 构件供应商选择研究

[187]. 外文电子期刊学术绩效评价体系构建与案例研究

[188]. Altmetrics 学术影响力传播贡献度实证研究*

[189]. Modelo de Evaluación y Acreditación para los Programas de Educación con Modalidad Virtual de la Corporación Universitaria Iberoamericana

[190]. 毕业要求与课程达成情况评价系统的研究

[191,194,197,212]. 向量数据库: 技术原理、应用场景与选型策略

[192,211]. 2026 年数据库技术深度研究报告

[193,195,431]. 向量数据库概述: Faiss、Milvus、Qdrant、Chroma、Weaviate

[196,199,432,460]. 在大模型应用爆发的今天, “向量数据库” 成了绕不开的关键技术

[198,201,204,207,459]. Застосунок для оперативного аналізу вмісту електронних документів з використанням штучного інтелекту

[200,208,433,454]. AI Agent 智能体技术发展报告

[202,205]. RAG-Based Query Engine using LLM and Vector DB for College Details

[203]. MADADGAR: A Retrieval-Augmented Generation (RAG) using Spring AI for College Specific Information

[206]. 向量数据库 (Vector Database) 是专门用于存储和检索高维向量的数据库系统

[209]. Retrieval-Augmented Generation for Telemedicine: A Privacy-Preserving AI Assistant for Healthcare

[210]. 向量数据库技术演进: 从传统搜索引擎到 AI 原生基础设施

[213,292]. 攻击者与防御者在 RAG 系统中的博弈: 安全与隐私的挑战

- [214,228]. RAG, Data Privacy, Attack Methods & Safe-Prompts
- [215,216]. RAG 系统安全与隐私：威胁模型与攻击面的形式化
- [217]. RAG Security and Privacy: Formalizing the Threat Model and Attack Surface
- [218,230]. The Conversational Network: AI-powered Language Models for Smarter Cable Operations
- [219,300]. RAG 初级面试问题
- [220,221,234]. 大模型开发 | RAG 在实际开发中可能遇到的坑
- [222,311,488]. User Experiences in a RAG-Empowered Application
- [223,227,231,489]. Design and Evaluation of a RAG Chatbot in an Industrial Setting
- [224,225,233,236,303,308]. CONVEGNO 2025 IBRIDAZIONI FECONDE SAPERI, PRATICHE, TERRITORI, RETE
- [226,235]. Managing Information Volatility and Density in Academic and Vocational Guidance: Modeling a RAG-based Chatbot for Guidance Counselors in Morocco
- [229]. VAGUE-Gate: Plug-and-Play Local-Privacy Shield for Retrieval-Augmented Generation
- [232,444]. 人工智能赋能高等教育高质量发展
- [237,245]. GLM-4-9B-Chat-1M 多轮对话优化：上下文记忆与一致性保持
- [238,241,257]. Qwen3-VL 多轮图文对话：上下文保持能力部署实测
- [239]. BAI Access Rules
- [240]. Qwen3-VL-8B 多轮对话：上下文保持部署优化技巧
- [242,247,250,260,262]. 如何在多轮对话中维持对话上下文
- [243,248]. Handle Long Text
- [244]. SCULPTOR: EMPOWERING LLMs WITH COGNITIVE AGENCY VIA ACTIVE CONTEXT MANAGEMENT
- [246,249,259,261]. ai 对话 上下文管理

- [251,254,258]. DeepSeek 多轮对话如何保持上下文一致性
- [252]. DeepSeek 多轮对话如何保持上下文一致性?
- [253,256]. 面试篇-Prompt
- [255]. 如何通过 ChatGPT 实现多轮对话的上下文保持?
- [263,266,269,271,278,455]. 向量数据库性能对比
- [264,281,284,286,461]. 向量数据库对比:Weaviate、Milvus 和 Qdrant
- [265,267,275]. LLM-Rag 原理解析_递归
- [268,273,276,456]. 向量数据库技术全景解析: 从核心架构到主流方案选型
- [270]. 开源向量数据库性能对比: Milvus, Chroma, Qdrant
- [272,279,282,287,457]. 【RAG 落地利器】Weaviate、Milvus、Qdrant 和 Chroma 向量数据库对比
- [274]. Comparison of Leading Vector Databases 2024-2025
- [277]. AI 大模型应用【理论】
- [280,288,289,290,291,458]. Qdrant vs Weaviate vs Milvus: Which Vector Database for Your RAG Pipeline?
- [283]. Vector Database Comparison: Weaviate, Milvus, and Qdrant
- [285]. Спосіб оптимізації роботи мікросервісної системи підтримки з використанням баз даних на основі моделі RAG
- [293,295,296]. Privacy Issues and Privacy-preserving Mechanisms in Retrieval-Augmented Generation Systems
- [294,298]. ADAM: A Systematic Data Extraction Attack on Agent Memory via Adaptive Querying
- [301,304]. 模型部署的安全与隐私保护
- [302,305,491]. Exploring Data Analysis Methods in Generative Models: From Fine-Tuning to RAG Implementation

[306,493]. Integrating Access Control with Retrieval-Augmented Generation: A Proof of Concept for Managing Sensitive Patient Profiles

[312]. 企业知识管理的研究与发现(2024 年)

[313,490]. RAG Chatbot System

[315]. 在 RAG (Retrieval-Augmented Generation) 系统中, 语义切片技术与多维度检索优化策略研究

[316,318,331,335,450]. RAG 应用构建及优化

[317,319,321,448]. Generative AI for Customer Support: An Empirical Investigation of RAG-Based Chatbot Architectures in an ERP Scenario

[320,451]. RAG 技术综述调研笔记

[322,325,327]. SEM RAG: 增强语义知识的 RAG 以改善问答系统 *

[323,326]. DENSE-RAG: Measuring and Improving Context Understanding for Consistent Retrieval-Augmented Generation

[324,330,449]. RAG 技术原理及实现

[328,332]. Effective Conversational AI: Chatbots that work

[329,333]. MoM: Mixtures of Scenario-Aware Document Memories for Retrieval-Augmented Generation Systems

[334]. 深入讲解如何在多轮对话中有效应用 RAG 技术

[336,341,343,344,345,464]. AI Agent 开发与应用: 基于大模型的智能体构建

[337]. RAGs 多轮对话优化: 上下文理解与对话状态管理技术

[338,342]. RAG 多轮对话系统设计与实现

[339,340,465]. rag 多轮会话

[349]. ВЕСТНИК НАУКИ

[350]. Building RAG systems at enterprise scale (20K+ docs): lessons from 10+ enterprise implementations

- [351,354,366,437]. AI 原生应用架构白皮书
- [359]. Entwicklung eines RAG-Systems für die semantische Suche nach wissenschaftlichen Publikationen
- [361]. 软件开发工作量评估标准
- [362,364]. 工作量评估
- [372,375]. Comparing Retrieval-Augmented Generation (RAG) and Traditional QA Systems
- [373,376]. rag-web-ui/docs/tutorial/README.md at main · rag-web-ui/rag-web-ui
- [374,377]. 合肥飞尔推出基于 RAG 的视频问答新技术，革新用户体验_向量_内容_系统
- [378,379,380,382,421,468,476]. RAG (Retrieval-Augmented Generation) 技术的创新方法综述
- [381]. EviNote-RAG: Enhancing RAG Models via Answer-Supportive Evidence Notes
- [383]. Build software better, together
- [384]. 教育类 RAG 系统技术方案全面对比
- [388,389,472]. “荔智规” 规章制度智能系统正式上线运行
- [390]. AI 时代的数据桥梁：如何利用 API 高效对接大模型，实现智能应用开发？
- [391]. Interview Guide：一个开源的智能面试平台
- [395,404]. RAG Playground: A Framework for Systematic Evaluation of Retrieval Strategies and Prompt Engineering in RAG Systems
- [396,400,405]. DESARROLLO DE UN SISTEMA DE CLASIFICACIÓN Y BÚSQUEDA DE ARTÍCULOS ACADÉMICOS MEDIANTE CADENAS CON MODELOS DE LENGUAJE Y CONTEXTUALIZACIÓN POR MODELOS RAG
- [398,399,407,412]. Evaluating RAG-based QA Systems: A Comparative Analysis of LLM as a Judge, Traditional Metrics, and Human Alignment
- [403,406,410]. Evaluation of RAG Metrics for Question Answering in the Telecom Domain
- [409]. CRAG – 综合性 RAG 基准测试

[411]. SPR-RAG: Semantic Parsing Retriever-Enhanced Question Answering for Power Policy

[413,414]. From Embeddings to Entities: A Comparative Analysis of RAG Architectures in Academic Domains

[415]. Evaluating Open-Source LLMs in RAG Systems: A Benchmark on Diploma Theses Abstracts Using Ragas

以下来源未被直接引用

EmbedLLM: Learning Compact Representations of Large Language Models

3D Multi-Object Tracking: A Baseline and New Evaluation Metrics

NLP-Experimente: Evaluation, Metriken und Signifikanz

Enhancing near duplicate image detection using spatial transformer networks in deep learning

Dialog System Technology Challenge 7

OLR 2021 CHALLENGE: DATASETS, RULES AND BASELINES

Coupled intelligent prediction model for medium- to long-term runoff based on teleconnection factors selection and spatial-temporal analysis

Learning industrial descriptions: NLP tasks for acronym expansion

SQUEEZE THE SOAKED SPONGE: EFFICIENT OFF-POLICY RFT FOR LARGE LANGUAGE MODEL

A dynamic knowledge base based search engine

Belief Change Functions for Multi-Agent Systems

LOGIC PROGRAMMING APPLICATIONS IN EDUCATIONAL ENVIRONMENTS

Dynamic Update Mechanism of the Knowledge Graph for AI Literacy Course

TOWARDS THE SEMANTIC WEB: KNOWLEDGE REPRESENTATION IN A DYNAMIC, DISTRIBUTED ENVIRONMENT

2025 年，RAG 技术到底进化成啥样了？

[Diseño e implementación de un asistente de aprendizaje basado en RAG](#)

[基于大模型和 RAG 的知识库问答系统](#)

[Leveraging Large Language Models for Firm-Intelligence: A RAG Framework Approach.](#)

[THELMA: 基于任务的大型语言模型应用的整体评估-RAG 问答](#)

[Ragas-评估指标](#)

[AI Coworker: Unbiased Artificial Intelligence System for Corporate Education through Document and Visual Media Processing](#)

[Prompt Versioning](#)

[PeopleSoft Campus Solutions 9.2: Campus Community](#)

[FILE SYSTEMS IN ML SETTINGS](#)

[北京市 2019 年政府工作报告](#)

[政府工作报告](#)

[运用 LangChain 赋能企业规章制度制定：深入解析 Retrieval ...](#)

[INFERSITY V1: A RETRIEVAL-AUGMENTED GENERATION \(RAG\) BASED CHATBOT FOR INTELLIGENT ACCESS TO UNIVERSITY RESOURCES](#)

[Retrieval Augmented Generation-Based Chatbot for Prospective and Current University Students](#)

[试论 EPC 总承包工程的进度计划管理](#)

[结直肠围术期加速康复外科护理管理与实施](#)

[Understanding RAG Systems Performance by Profiling Key Factors](#)

[构建生产级检索增强生成（RAG）系统时的评估挑战与解决方案](#)

[Aprimorando o atendimento ao cidadão com RAGLC \(Retrieval Augmented Generation in Logic Context\), uma nova abordagem RAG](#)

[手术机器人行业深度：引领临床新变革，商业化大潮蓄势待发](#)

[准确评价学术成果的社会影响力](#)

Questionnaire validation on the perception and satisfaction of academics with professional evaluation systems

《开放存取期刊学术影响力研究》

基于 CSSCI 的图情类期刊 h 指数评价研究

特征因子与影响因子及总被引频次的指标特性比较——基于“TOP 期刊 ...

Evaluating RAG Technologies for News Technical Report TR 093

多模态大模型：从理论到实践

基于 RAG 技术的本地化智能问答系统

Privacy Issues and Privacy-preserving Mechanisms in Retrieval-Augmented Generation (RAG) Systems

Practical LLM Security: Takeaways From a Year in the Trenches

中央预算内投资 | 政策汇编（2016.04-2024.04）

EPC 工程总承包企业的核心竞争力要素分析与评价研究

Leveraging Retrieval-Augmented Generation for Student Support: A Document-Centric QA System for the AUEB Informatics Studies Guide

Action-Item-Driven Summarization of Long Meeting Transcripts

2025 低空经济 重点政策汇编

文本处理

LCFO: Long Context and Long Form Output Dataset and Benchmarking

Label-dependent Paragraph Selection for Efficient Neural Long Document Classification

向量数据库深度对比：Weaviate、Milvus 与 Qdrant

Qdrant vs Milvus

Milvus vs qdrant - compare differences and reviews? | LibHunt

向量数据库选型对比

[Qdrant Vs Milvus Comparison](#)

[PaperHelper: 基于知识的 LLM 问答论文阅读助手](#)

[DBMS > Milvus vs. Qdrant](#)

[Milvus vs. Qdrant](#)

[AI Agent 进化全景：从语言问答到具身智能的技术、商业与治理生态](#)

[大语言模型安全技术发展趋势（三）](#)

[【大模型】RAG 实践](#)

[AuditRAG: An ARAG Approach for Auditing Dutch Annual Reports: Ensuring Compliance](#)

[SAGE: A Framework of Precise Retrieval for RAG](#)

[一种基于 RAG 的多轮对话处理方法、装置以及设备](#)

[基于 2025 年最新开源项目调研的多模态 RAG 系统评估报告](#)

[软件工作量评估标准](#)

[Challenges in Evaluating RAG System Performance](#)

[SIGIR 2024 获奖结果公布，清华计算机系斩获多项大奖](#)

[DeepSolution](#)

[【Java 项目创新】AI 问答聊天系统、仿 ChatGPT 系统，基于 Springboot+Vue+本地大语言模型，可作为毕业设计创新点添加_哔哩哔哩_bilibili](#)

[2024 最新版 Transformer！从入门到实战，原理解读+源码复现，全程干货讲解，拿走不谢！_哔哩哔哩_bilibili](#)

[RAGFlow](#)

[2025 年“人工智能+”行业标杆案例荟萃](#)

[谈 EPC 总承包的成本控制](#)

[論文を対象とした RAG システムにおける質問分類に基づく動的検索](#)

[Reasoning-Intensive Regression](#)

内容为 AI 生成，可能不准确，请谨慎参考

[CRAG -- Comprehensive RAG Benchmark](#)

[HubLink: A Novel Question Answering Retrieval Approach over Knowledge Graphs](#)

[【AIGC】大模型面试高频考点-RAG 系统评估](#)